RAF Prompt Optimization: Readability Improvement and Analysis

前置总览与风险说明

> 背景：RAF（ACL2026）核心：**冻结 LLM 权重，只优化输入侧的离散 token，做两阶段优化，用来操纵 LLM 排序结果**，属于 Prompt Optimization/Token-level adversarial prompt，不是微调大模型。
> 导师目标不是做出 SOTA，**重点考察：读懂论文、复现最小实验、提出有依据改进、对照实验、完整报告，以及区分 LLM 建议和自己的思考**。允许结果不涨点，重点看分析。
> 时间窗口：7 天。你是零基础入门大模型输入优化，我把任务拆成**Day1~Day7**，每天明确目标、产出物、难点、辅导重点。
> 硬件前提确认（第一天第一件事）：
> 最少显存需求：选小模型，例如 `Llama-2-7b-chat` / Mistral-7B，单卡至少 24G 显存（A10/3090/A10G）；如果只有 16G，可以用 4bit 量化加载模型。**全程冻结模型参数，只优化输入 token，模型只做推理，不反向更新权重**。

> 任务精简范围（和导师对齐，只做小规模实验，不跑全量）
> 模型：Mistral-7B-Instruct（推荐，权重小，速度快，比 Llama2 更容易跑通）
> 商品类别：选 `electronics`（电子产品，data2/json 里现成）
> 目标商品：选 2 个目标 item（比如 id=1、id=2），控制实验规模。
> 基线：原始 prompt 排序（baseline）、原始 RAF、你的改进方法三组对照。评价指标：平均排名、hit@1（排名第一比例）、人工抽查 prompt 可读性。

整体交付清单（最后一天打包提交）

1. 可运行代码：最小复现脚本 + 改进版本脚本 + 结果统计脚本
2. 实验表格 + 日志（三组结果）
3. 3 页 PDF 报告
4. 10 分钟 PPT 汇报稿
5. 过程文档：思路取舍记录、LLM 提示词样例（满足 “区分模型建议与自己判断” 要求）

---

7 天详细任务计划

Day1：读懂论文 + 熟悉仓库代码，搭建环境（目标：理解 RAF 原理，环境跑通最小 demo，产出：笔记 + 可用环境）

> 核心难点：区分「冻结模型，优化输入 token」，两阶段优化是什么，损失函数。

今日任务

1. 论文精读（aclanthology 2026.acl-long.413）
   - 先读摘要 + intro+method（重点！结果和实验部分可以粗略看）
   - 记录核心概念：
     - RAF：Two-Stage Token Optimization，**固定 LLM，优化输入 prompt 中的离散 token，诱导 LLM 把目标商品排到第一名**
     - Stage1：**粗粒度搜索**，替换候选 token，最大化目标商品排序得分，快速找到候选 prompt；
     - Stage2：**细粒度微调（token 层面）**，在 stage1 得到的 prompt 附近做局部 token 优化，进一步提升排名；
     - 损失函数：**排序损失 pairwise ranking loss**，目标商品分数 > 其他所有候选商品分数。
     - 关键限制（后面你的改进就针对这些局限，记下来）：
       ① 优化出来的 token 经常是乱码、不可读、语义崩坏；
       ② 两阶段独立，stage1 的错误会传递到 stage2；
       ③ 离散 token 搜索空间巨大，容易陷入局部最优；
       ④ 只优化排序目标，没有约束 prompt 自然语言可读性。
2. 拉取官方 RAF 仓库，通读代码结构

   代码块
   ```
   git clone https://github.com/glad-lab/RAF.git
   cd RAF
   ```

   看懂目录：`data2/json` 是商品排序数据集；看 `main.py`、`optimizer` 文件夹，定位两阶段优化、损失计算代码。**不用直接全量跑，只看懂数据流**。
3. 搭建 conda 环境，安装依赖：torch、transformers、accelerate、bitsandbytes（量化）、evaluate 等。
   测试：加载 Mistral-7B，做一次简单排序推理，确认 GPU 可用。
4. 选好实验固定配置，写在实验配置文档（后面所有实验固定，不能调参）
   - 模型：Mistral-7B-Instruct 4bit 量化
   - 数据集子集：electronics 类别，候选商品列表固定，2 个目标商品

- 评价指标：平均 rank，Hit@1（目标商品排第 1 的比例）

> 今日产出：
> 论文手写笔记（方法 + 损失 + RAF 局限）；环境成功加载模型；实验配置文档。

✅ 辅导任务 Day1 结束后：你把论文 method 部分看不懂的段落发给我，我翻译成大白话，拆解损失函数公式，解释代码对应位置。

Day2：最小规模 RAF 复现，跑通原始 RAF 实验（目标：跑通 baseline + 原始 RAF，拿到第一组结果）

> 目标：**不要跑全部数据！小规模子集，1 个商品分类，2 个目标商品，候选列表控制在 8~10 个商品**

今日任务

1. 数据预处理：从 `data2/json/electronics` 抽取子集。
   构造每个样本：给定 query + 候选商品列表，LLM 输出商品排序。
   - Baseline：原始描述 prompt，不做任何 token 优化，直接让 LLM 排序。
   - RAF：官方两阶段 token 优化，固定模型，优化输入 token，诱导 LLM 把目标商品排最高。
2. 裁剪官方代码：删除大规模实验、多模型循环，只保留单模型、单类别、2 目标商品的最小版本脚本。

   > 坑提醒：RAF 是**离散 token 优化**，不是梯度直接更新 embedding；离散 token 不能直接求导，论文里用的是 token 替换采样策略，这点很关键，别和连续 prompt embedding 攻击混淆。
3. 运行两组实验：Baseline、原始 RAF。
   记录指标：每个目标商品的平均排名，Hit@1；保存生成的优化后 prompt 文本，后面看可读性。
4. 观察现象：RAF 优化出来的 token 大概率出现乱码、无意义字符（这就是论文里的一个痛点，正好是你改进的切入点）

> 今日产出：
> 精简可运行复现代码；baseline+RAF 实验日志与结果表格；记录 RAF 生成 prompt 可读性问题。

✅ Day2 辅导：你卡住时，我帮你定位代码中 Stage1/Stage2、pairwise loss 部分，区分离散 token 优化与连续 embedding 优化。

Day3：调研相关论文，锁定改进方向（核心环节，导师重点考察！产出：2 篇参考文献 + 改进方案）

要求：至少两篇相关论文，不能随便找，要和**LLM 排序、prompt 优化、离散 token 优化、对抗 prompt、可读性约束**相关。

推荐候选论文（优先选）

1. Prompt Optimization with Constrained Language Models (约束 prompt 优化，增加可读性正则)

2. Discrete Prompt Optimization via Reinforcement Learning for LLM Attacks
   或者：

- AutoPrompt（经典离散 prompt 搜索）
- GCG（Greedy Coordinate Gradient，LLM 对抗 token 优化，和 RAF 技术同源，强烈推荐）

今日任务

1. 阅读 2 篇论文，提炼核心方法，对比 RAF 的不足
   从 Day1 记录的 RAF 局限里挑一个痛点作为你的改进目标，**推荐方案（难度适中，好落地，有深度，适合 7 天工程实现）：**

   > 改进思路推荐：**在 RAF 两阶段优化的损失函数里，增加自然语言可读性正则项**
   > 原始 RAF 只优化 pairwise 排序损失，完全不约束 token 可读性，优化出来的 prompt 大量乱码，人类无法阅读。
   > 改进：总 Loss = 排序 pairwise loss + λ * 语言模型困惑度 (PPL) 正则。PPL 衡量文本流畅度，惩罚低可读性乱码 token。
   > 为什么有创新：原始 RAF 只关注操纵排名，完全无视 prompt 可读性；GCG/AutoPrompt 也很少同时做「排序任务 + 流畅度约束」。区别于单纯调参，新增一个显式正则目标。
   > 备选思路（如果你觉得 PPL 不好实现）：
   > 思路 B：修改两阶段结构，Stage2 不再独立优化，每一步优化都回传给 stage1 做校验，减少错误传递。

2. 论证：写清楚
   - RAF 原有局限是什么
   - 你的改进解决哪个局限
   - 参考文献里面的相关工作怎么做，你的方案和它们的区别
   - 潜在风险：加正则后可能降低操纵排名效果（Hit@1 下降，完全可以接受，只要你后面分析原因）
3. 记录方案取舍：写下你**考虑过哪些备选方案，为什么放弃**（导师重点想看这一段，写进报告）
   例：
   - 方案 A：替换 token 搜索策略为强化学习，放弃：RL 训练复杂，7 天内很难收敛，工程量大。
   - 方案 B：只修改学习率，放弃：只是调参，没有理论依据，不满足导师要求。
   - 方案 C：增加 PPL 可读性正则，保留：改动小，直接修改 loss，代码改动量可控，有文献支撑，目标明确。

> 今日产出：2 篇论文阅读笔记；正式改进方案文档；方案取舍记录。

✅ Day3 辅导：如果你拿不准改进思路，我帮你对比不同方案的优劣，帮你写清楚 “和已有工作的区别” 段落。

Day4：实现你的改进版本代码 + 调试

今日任务

1. 在 Day2 精简 RAF 代码基础上修改：**新增正则项，修改总损失函数**
   原始 RAF Loss = PairwiseRankLoss
   改进 Loss = PairwiseRankLoss + λ * PPL (prompt_tokens)
   λ 是正则权重（**λ 固定！不能拿测试集调 λ，λ 在训练 / 优化阶段固定，测试条件不参与调参**，满足导师要求）
2. 调试 bug：重点检查：
   - 模型权重全程冻结，只有输入 token 被优化
   - PPL 计算逻辑：用同一个 LLM 计算当前优化 prompt 的困惑度
3. 准备三组对照实验（固定全部超参，保证计算预算一致）
   ① Baseline：原始 prompt
   ② RAF 原版：无正则
   ③ RAF+PPL 正则（你的改进）

> 今日产出：改进版本完整代码；调试日志。

✅ Day4 辅导：帮你写 loss 修改的代码片段，解释 PPL 计算实现，排查维度、梯度、token 采样 bug。

Day5：完整对照实验，收集结果，定性可读性抽查

> 重要规则：三组实验**GPU 环境、候选商品列表、目标商品、优化迭代次数完全一致**，保证相同计算预算，公平对比。不能为了效果手动调参。

今日任务

1. 运行改进版本实验，记录指标：平均排名、Hit@1。
2. 收集三组生成后的 prompt 文本，人工抽查可读性：看是否乱码、语义通顺程度。
3. 整理结果表格：
方法	目标商品 1 平均 rank	目标商品 1 Hit@1	目标商品 2 平均 rank	目标商品 2 Hit@1	可读性描述
Baseline					原始 prompt，可读
RAF 原版					大量乱码
RAF+PPL (改进)					乱码减少，可读性提升
4. 结果分析：
   两种可能性，都可以写进报告：

- 情况 1：Hit@1 轻微下降，但 prompt 可读性明显变好 → 分析：可读性正则和排序操纵目标存在权衡，牺牲一点排名攻击能力换取 prompt 可读性。
- 情况 2：Hit@1 不变，可读性提升 → 分析：正则有效，没有明显损害排序操纵效果。

> **不要求改进超过 RAF，导师允许效果变差，重点是严谨分析原因！**

> 今日产出：完整实验结果表格；原始 / RAF / 改进版生成 prompt 样例；初步结果分析草稿。

✅ Day5 辅导：一起解读结果，撰写结果分析，区分是方法本身权衡还是代码 bug 导致。

Day6：撰写 3 页报告 + 整理 LLM 使用记录（导师重点考察项）

> 报告控制：3 页，学术小报告，结构如下：
> Page1：背景、RAF 方法简述，研究问题（RAF 优化 prompt 可读性差的局限）
> Page2：相关工作（2 篇参考文献），你的改进方法，损失函数，实验设置（写明：和原论文差异：小规模子集、Mistral7B，没有跑全类别）
> Page3：实验结果、可读性抽查、结果分析、局限、未来方向

额外强制内容：使用 LLM 的过程记录

> 导师要求：可以使用 LLM，但是要展示提示词，区分模型建议和自己判断。
> 写法示例（放进报告附录）：
> 提示词样例 1：`解释RAF论文两阶段token优化，损失函数，用大白话说明，不要公式堆砌`
> LLM 输出：xxxx
> 我的判断：LLM 对离散 token 采样描述有偏差，查阅论文原文修正，确认 RAF 不是连续 embedding 优化。
> 提示词样例 2：提出改进 RAF 的方案，不要简单调参
> LLM 建议：xxx（比如 RL 方案）
> 我的取舍：RL 工程难度太高，7 天无法完成，放弃；选择 PPL 正则方案。
> 核心：**写明你如何校验、筛选、拒绝不合适的 LLM 建议**。

今日产出：3 页报告初稿；LLM 使用记录；代码 + 数据打包。

✅ Day6 辅导：帮你润色报告学术表述，精简到 3 页，补充「与原论文实验差异」段落。

Day7：准备 10 分钟汇报 PPT，自查全部材料，最终打包提交

1. 10 分钟汇报结构（严格控制时间）
   0-1min：背景：LLM 作为排序器是否可靠，RAF 是什么任务
   1-3min：RAF 原理，两阶段优化、损失，原始方法局限
   3-5min：相关论文，改进思路、损失函数，方案取舍
   5-8min：实验设置、结果表格、可读性对比，结果分析（哪怕效果下降也要分析）
   8-9.5min：LLM 使用说明，如何区分模型建议和独立思考
   9.5-10min：总结，局限，后续方向

2. 自查全部交付物清单：
   ✅ 可运行代码（附带 readme，写明如何启动，环境依赖）
   ✅ 实验结果、日志
   ✅ 3 页报告 PDF
   ✅ 10 分钟 PPT
   ✅ LLM 提示词 + 思考取舍记录
3. 预演一遍汇报，压缩到 10 分钟。

> 今日产出：全套提交包；完成 10 分钟试讲。

关键避坑清单（导师非常看重）

1. ❌ 严禁：在测试集上调超参（λ，迭代次数等）。所有超参在实验前固定。
2. ❌ 严禁：把 “调学习率 / 换模型 / 改 prompt 模板” 当成改进。改进必须针对论文提出的具体局限，有文献支撑。
3. ✅ 必须写明**和原论文实验差异**：原论文多类别、多模型、大量目标商品；本任务仅 electronics，Mistral7B，2 个目标商品，小规模子集。
4. ✅ 明确区分：**冻结 LLM 权重，只优化输入 token，不是微调 LLM**，答辩一定要强调这个，证明读懂论文。
5. ✅ 允许改进方法指标不如原始 RAF，**分析优先级 > 指标高低**。

下一步

你可以从 Day1 开始，我们可以按天推进。
先告诉我两件事：

1. 你可用 GPU：显卡型号、显存大小，是否可以用 bitsandbytes 做 4bit 量化?
2. 你读论文的时候，优先从哪一部分开始：先看论文 Method 章节，还是先看 github 代码?